

NO. a70482af1081e83d | 2025-06-03 23:48:12

- 题目：基于预训练嵌入和数据增强DTI预测
- 作者：LOW REN HONG
- 检测所属单位：浙江理工大学

📄 论文字符数：33764 📄 论文页数：49 📊 表格数量：8 🖼️ 图片数量：25

检测结果



15.57%

全文总相似比(复写率+他引率+自引率+专业术语)

相似结果详情

14.07%	0.0%	1.5%	0.0%
复写率	自引率	他引率	专业术语

其他指标

去除本人引用相似率：15.57% 去除专业术语相似率：15.57% 自写率：84.43%

典型相似文章：无

检测范围 | 1989-01-01 ~ 2025-06-03

- 中文科技期刊论文全文数据库
- 中文主要报纸全文数据库
- 古籍文献/图书资源
- 港澳台文献资源
- 高校自建资源库
- 博士/硕士学位论文全文数据库
- 中国专利特色数据库
- IPUB原创作品
- 年鉴资源
- 外文特色文献数据全库
- 中国主要会议论文特色数据库
- 互联网数据资源/互联网文档资源
- 维普优先出版论文全文数据库

相似片段

相似片段：

151	141	10
总相似片段	相似片段	引用片段

检测来源：

期刊 14	综合 29	外文 0
博硕 49	互联网 43	自建库 16

引用文献汇总

引用文献来源：10

序号	引用文献	引用字符数	引用率	来源
1	基于深度神经网络的药物-靶标相互作用预测方法研究 朱晨熠 - 2024	73	0.31%	自建库
2	基于Stacking融合模型的高血压风险预测研究 刘洋 - 2023	68	0.29%	博硕
3	互联网论文-2118466	66	0.28%	互联网
4	大模型里面常说的Embedding（嵌入）是什么 - CSDN博客	62	0.26%	互联网
5	基于深度学习的药物-靶标相互作用预测研究综述 刘晓光;李梅 - 智能系统学报 - 2024	56	0.24%	期刊
6	《2024年度医疗器械注册工作报告》显示我国创新医疗器械 ...	52	0.22%	互联网
7	面向智能问答系统的语义匹配技术研究与实践 韩华珍 - 2021	43	0.18%	博硕
8	基于交叉半监督机器学习算法的滑坡易发性评估方法及系统 赵鹏;何展昌;王维;邓丽娟;李锐;曾庆尧;黄磊;王发志 - 2024	42	0.18%	综合
9	大学生毕业论文-71755	38	0.16%	互联网
10	一种药物分子与靶标蛋白的结合亲和力预测方法	38	0.16%	互联网

相似文献汇总 (当前只展示10条数据,全部详情请查看片段对照报告)

相似文献来源：120

序号	相似文献	相似字符数	相似率	来源
----	------	-------	-----	----

1	基于深度神经网络的药物-靶标相互作用预测方法研究 朱晨熠 - 2024	498	2.09%	自建库
2	2020339920012_孙斓绮_基于机器学习的车位规划 孙斓绮 - 2024	235	0.99%	自建库
3	一种基于自然语言处理技术的抗癌肽识别方法 陈涛;朱云平;徐小放;韩明飞;陈浣清 - 2024	137	0.58%	综合
4	一种货物仓储管理系统及方法 蒋舜; 张明剑; 董彬; 谢轲; 李书云 - 2024	134	0.56%	综合
5	基于图注意力和蛋白质语言模型的药物靶标亲和力预测 任鹏;段乐乐 - 软件 - 2024	132	0.55%	期刊
6	互联网论文-170282	110	0.46%	互联网
7	一种基于无监督学习神经网络的光纤通信信道均衡方法 杨慧;郭虹;邓鹏程 - 2023	103	0.43%	综合
8	基于深度学习的药物-靶标相互作用预测研究综述 刘晓光;李梅 - 智能系统学报 - 2024	98	0.41%	期刊
9	基于深度学习的语音情感识别研究 李淑贞 - 2020	89	0.37%	博硕
10	互联网论文-16146	87	0.37%	互联网

文字标注

■ 自写片段
■ 复写片段
■ 引用片段
■ 专业术语
■ 自引片段



浙江理工大学

本科毕业设计（论文）

题 目 基于预训练嵌入和数据增强DTI预测

学 院 计算机科学与技术学院（人工智能学院）专业班级 计算机科学与技术(留学生)21(1)

姓 名 LOW REN HONG 学 号 2021529620004

指导老师 曾煜妮

系 主 任 沈炜 学院院长 许威威

二〇二五 年 六 月 三 日

浙 江 理 工 大 学 毕业设计(论文)诚信声明

本人郑重声明：我恪守学术道德，崇尚严谨学风。所呈交的毕业设计(论文)是本人在导师的指导下，独立进行研究工作所取得的成果。本人所写的毕业设计(论文)，凡引用他人的研究成果均已在参考文献或注释中列出。设计(论文)主体均由本人独立完成，没有抄袭、剽窃他人已经发表或未发表的研究成果行为。如出现以上违反知识产权的情况，本人愿意承担相应的责任。

学校有权保留本毕业设计(论文)，允许被查阅和借阅，可以将本毕业设计(论文)的内容编入有关数据库进行检索或向上级有关部门送交本毕业设计(论文)。

声明人(签名):

Low Ren Hong

20年256月3 日

摘 要

随着计算机的持续增长，大数据的普及以及医学上的日益增长。药物靶标相互作用是药物发现中的核心发展，DTI是指的药物与靶标比如蛋白质，酶等之间的相互作用。药物可以通过激活或抑制靶标功能来产生疗效，药物可能不只作用与单个靶标。只有选对了药物和预期的靶标有效结合才能产生治疗作用，当药物与非期望靶标发生相互作用可能导致不良反应。DTI预测可以加速药物发现过程，由于人工实验的方法成本高，耗时长。所以使用深度学习模型可以加速药物的发现。但是在现有的深度学习模型中仍存在特征提取不足对应小数据集的问题，所以提出了一种基于预训练嵌入和数据增强的DTI预测，在实验中预训练嵌入和特征提取能够更精准的识别DTI。

针对以上问题，首先，根据少样本的问题导致模型的过拟合，本文引入数据增强以及正则化和早停。其次，根据特征提取的不足，提出了使用预训练模型来进行特征嵌入。本文使用卷积神经网络，共享权重的双向多头交叉注意力，预训练模型进行特征提取。药物采用基于SMILES编码的ChemBERTa的预训练模型进行特征提取和蛋白质基于氨基酸序列的ProtT5的模型来进行特征提取。通过预训练嵌入和数据增强，在实验中达到了有效的提高了模型的准确率。在二分类中以MCANet为基线Davis数据集的准确率从0.8927提高至0.9425，而Kiba数据集则0.9168提高至0.9447，相对于回归中以DeepDTA为基线Davis数据集的CI（一致性指数）0.878提高至0.9435，而Kiba数据集从0.863提高至0.9364，验证了此方法的是可行的。

关键词：药物靶标相互预测的作用；预训练嵌入；数据增强；卷积神经网络；多头注意力机制；

Abstract

With the growth of computing power, the proliferation of big data, and the in-creasing advancements in medicine, drug-target interactions have become a core focus in drug discovery. DTIs refer to the interactions between drugs and targets such as proteins or enzymes. Drugs can produce therapeutic effects by activating or inhibiting the functions of these targets. However, drugs may not interact with just a single target. Only when a drug effectively binds to the intended target can it produce the desired ther-apeutic effect, while interactions with unintended targets may lead to adverse reactions. DTI prediction can accelerate the drug discovery process, as traditional laboratory meth-ods are costly and time-consuming. Therefore, deep learning models are employed to speed up drug discovery. However, existing deep learning models still face challenges with insufficient feature extraction, particularly when dealing with small datasets. To address this, we propose a DTI prediction method based on pre-trained embeddings and data augmentation. In experiments, pre-trained embeddings and enhanced feature extraction enabled more accurate identification of DTI.

To tackle the issues, we address the problem of overfitting caused by small sam-ple sizes by introducing data augmentation, regularization and early stopping. Second, for insufficient feature extraction, we propose using pre-trained models for feature em-bedding. Our approach employs a convolutional neural network with shared weights multi-head cross-attention, and pre-trained models for feature extraction. Specifically, for drugs, we use the ChemBERTa pre-trained model based on SMILES encoding for feature extraction, and for proteins, we use the ProtT5 model based on amino acid se-quences. In binary classification tasks, using MCANet as the baseline, the accuracy on the Davis dataset increased from 0.8927 to 0.9425, and on the Kiba dataset from 0.9168 to 0.9447. In regression tasks, using DeepDTA as the baseline, the Consistency Index (CI)on the Davis dataset improved from 0.878 to 0.9435, and on the Kiba dataset from 0.863 to 0.9364, validating the effectiveness of our approach.

Keywords: Pre-trained feature extractionData augmentationCNNMultihead atten-tion

目 录

摘 要

Abstract

第1章 绪论 ····· 1

1.1 研究目的与意义 ····· 1

1.2 国内外研究现状与分析 ····· 2

1.2.1 国内外研究现状 ····· 2

·····

1.3 选题意义	3
1.3.1 现实意义	3
1.3.2 技术意义	4
1.4 非技术因素分析	4
1.5 论文结构安排	4
第2章 药物靶标相互预测作用的技术和方法的介绍	6
2.1 DTI的预测和结合亲和力预测介绍	6
2.2 预训练模型的嵌入	6
2.3 数据增强技术	7
2.4 MCANet模型的原理	7
2.4.1 输入设置	7
2.4.2 构建模型	7
2.5 DeepDTA模型的原理	9
2.5.1 输入设置	9
2.5.2 构建模型	9
第3章 基于预训练嵌入和数据增强的DTI预测	11
3.1 预训练嵌入	11
3.1.1 药物的预训练嵌入	11
3.1.2 蛋白质的预训练嵌入	12
3.2 数据增强	12
3.2.1 药物的数据增强	12
3.2.2 蛋白质的数据增强	12
3.3 模型	13
3.3.1 卷积神经网络	13
3.3.2 双向多头交叉注意力机制	14
3.4 实验与结果	14
3.4.1 数据集	14
3.4.2 药物基于预训练嵌入和数据增强	15
3.4.3 蛋白质基于预训练嵌入和数据增强	16
.....	

3.4.4 评估指标	16
3.4.5 实验设置	18
3.4.6 实验结果	19
第4章 基于预训练嵌入和数据增强的药物-靶标亲和力预测	22
4.1 预训练嵌入	22
4.1.1 药物的预训练嵌入	22
4.1.2 蛋白质的预训练嵌入	22
4.2 数据增强	23
4.2.1 药物的数据增强	23
4.2.2 蛋白质的数据增强	23
4.3 模型	23
4.3.1 CNN	24
4.3.2 共享注意力机制	25
4.4 实验与结果	26
4.4.1 药物基于预训练嵌入和数据增强	26
4.4.2 蛋白质基于预训练嵌入和数据增强	27
4.4.3 评估指标	28
4.4.4 实验设置	29
4.4.5 实验结果	30
第5章 UI可视化界面	33
5.1 DTI的首页	33
5.2 数据集	33
5.3 DTI	35
5.4 导出预测数据CSV	35
第6章 总结与展望	37
6.1 主要研究成果和结论	37
6.2 展望	37
参考文献	39
致 谢	42

第1章 绪论

1.1 研究目的与意义

在新冠疫情的推动下，全球药物研发引来了前所未有的改革医药行业不断的加速和创新。截止2024年，国家药监局共批准创新医疗器械65个^[1]和截至2024年7月，累计批准的创新医疗器械数量达到277个^[2]。如何充分的利用机器学习的资源，提高药物靶标相互作用预测的准确率是当前药物发展的重要问题。^[3]

随着药物研发对于高效的准确药物靶标相互作用预测提出更高的需求。而在这种情况下，随着人口老龄化加速、人们的消费水平及医疗需求不断上升，相关医疗卫生支出将会保持持续的增长^[4]。但也会造成了药物预测压力大，因为研发昂贵以及不足问题，但又要如何充分的时候医学器材来进行药物靶标相互预测成了当前药物发展的紧迫问题^[5]。

利用机器学习的卷积神经网络来进行药物靶标相互预测作用是一种极为有效的解决方案。^[6]在同等于相同的资源下，相对于传统的药物研发成本高，研发周期长，失败率高，难进行大规模的药物标相互识别工作。^[7]从1993年至今，FDA (United States food and drug administration) 每年批准的新药数量增长十分缓慢。《FDA罕见用药法案》定义的罕见疾病低于20万美国患病率的疾病超过7000种，95%以上的疾病没有相应的治疗药物。^{[8][9]}

已经有大量的相关的研究比如，在药物靶标相互预测相互作用中主要分为两类任务，判断药物和靶标中是否存在作用里和预测相互作用中的亲和力。尽管亲和力不等同于临床疗效，但研究表明药物与靶标的高结合亲和力往往是产生良好药理效果的前提条件。^[10]第一，药物靶标相互是否存在作用是个经典的二分类问题，使用已知的正样本和副样本来进行训练，最后输出的0或1表示存在相互作用。第二，预测相互作用中的亲和力，亲和力是衡量药物和靶标之间的相互作用强度，用的CI等来衡量。研究发现药物与靶标的亲和力是衡量其临床疗效的重要指标。此外，针对机器学习的方法在药物靶标相互预测里主要包括了传统机器学习方法和深度学习方法^[11]。在利用机器学习中来对药物靶标相互作用预测能减少药物研发的周期和成本，虽然药物靶标相互作用预测有许多优点，但依然存在以下的不足。

在药物靶标相互作用的预测，对于小数据集的样本数据有限导致了正样本稀缺^[12]，导致模型训练容易过拟合，所以本文引入了数据增强来缓解小模型容易过拟合的现状。相对于传统方法在提取药物分子和靶标蛋白质的特征时，可能无法全面捕捉其化学和生物特性^[13]，特别是在建模化学空间与基因组空间的关系时存在困难是，所以本文引入了预训练模型的数据嵌入作为数据的嵌入。基于以上背景，本文我们致力于设计和开发基于预训练嵌入和数据增强的DTI预测并进行可视化展示。

1.2 国内外研究现状与分析

1.2.1 国内外研究现状

近年来，药物靶标相互预测作用在深度学习的推动下，可分为两类的预测。其主要的预测是二分类问题和回归问题。二分类问题将输入数据分为0或1来输出。例如：最常见的就是垃圾邮箱，语义分析是个正类还是副类，疾病预测等等。而回归任务的话是输出是药物靶标相互预测作用的结合亲和力，例如：最基本的是预测房价，设备剩余寿命预测，学生成绩预测等等。

从药物靶标相互预测作用的角度来分析，二分类问题主要的核心挑战就是对于数据不平衡性以及特征提取的瓶

颈。对于二分类的模型，常用模型有逻辑回归，支持向量机，决策树，随机森林等。Yamanishi et al.^[14]在2008年提出的基于药物与靶标相似性的方法，首次将药物与靶点的相似性纳入一个统一框架。该核心采用的是SVM的方法进行实现的，该方法的创新点使用了统一框架和SVM的运用来提高准确率。随后在2008年Jacob et al.^[15]提出了使用SVM在蛋白质-配体相互作用预测。通过将蛋白质和配体的特征进行编码并映射到一个特征空间，能够使用SVM来训练作为一个分类器用来预测蛋白质-配体相互作用是否存在。然而，在2020年NeoDTI^[16]利用了异构图网络(HGN)进行预测，它利用图神经网络(GNN)来整合多种类型的节点和边信息。尽管这一方法具有很大的优势，能够捕捉多模态信息的关系，但异构图的构建和训练需要处理大量节点和边，计算成本较高。以及在2023年，MCANet提出了共享权重的多头交叉注意力机制，来提高预测性能，引入了PolyLoss来提升模型的泛化能力。

回归任务的问题，在20世纪初期，AutoDock成了分子对接的重要工具，基于三维结构模拟药物分子与靶标结合。^[17]它为药物靶标相互作用的预测提供了计算化学和分子模拟的方法。接着是QSAR是2000年随着生物信息学和计算机科学的快速发展，成为现代药物发现中不可或缺的工具之一。随着机器学习方法的逐步成熟也随着深度学习的算法普及，2017年DeepDTA^[18]引入了CNN，从原始数据(SMILES和序列)中直接学习特征。特点是回归任务不会忽略亲和力和力值。2019年，GraphDTA^[19]使用图神经网络(GNN)结合分子和靶标特征，提高了预测性能，但依然存在以下问题随着数据规模的扩大，模型的训练时间和内存需求可能成为瓶颈。

由此可见，这些模型都有各自的特点，比如Yamanishi采用的统一框架，NeoDTI利用了异构图网络和图神经网络来整合多种类型的信息，DeepDTA引入了CNN通过直接从药物和靶标的原始数据中**学习特征，预测药物与靶标之间的结合亲和力**，MCANet使用了共享权重的多头交叉注意力机制和PolyLoss来提升模型。

当前基于深度神经网络的药物靶标相互预测作用预测的方法有着很好的结果，但是依然面临着许多的挑战。第一点是少样本的问题主要实验成本高，数据稀缺等问题。少样本的后果会导致模型性能下降比如过拟合等问题。当训练数据不足时，模型可能记住训练样本而非学习通用规律，导致在测试集或新数据上的表现较差。第二点是不足特征提取不足是指在药物-靶标相互作用(DTI)预测中，无法从药物分子和靶标蛋白的数据中全面提取出能够反映其关键生物特性、化学性质和交互机制的有效特征。主要的因素是特征表示不充分，在传统手工设计的特征(如分子指纹、物理化学描述符)可能难以全面捕捉药物和靶标的深层次信息^[20]。

1.3 选题意义

1.3.1 现实意义

为了降低研发的成本，对于传统的药物靶标预测使用实验来进行测试，价格昂贵以，实验的周期长和耗费人力。此外，对于实验的失败率高，许多的药物靶标在验证中被证明无效导致资源的浪费。因此，近年来基于深度学习的DTI预测方法成为了研究热点，能够更快的筛选出相互作用对，从而降低研发的成本。在此之上，本文提出了基于预训练嵌入和数据增强的DTI预测，能够有效的结果解决当前的问题。首先，对于小样本的数据集容易导致模型的过拟合，因此使用了数据增强的多样性来解决小数据集的问题。特征提取不足导致模型无法全面捕捉药物和蛋白质之间的关系所以使用了预训练模型的嵌入来解决特征提取不足以及解决了模型在特征提取中从头开始提取的问题。

1.3.2 技术意义

这是个跨学科融合的技术，我们通过药物靶标相互作用预测中，涉及到生物信息学、计算机科学、化学等多个学科的交叉，探讨如何将这些学科的知识融合，进一步推动计算机辅助设计的发展。我们可以利用深度学习和机器

学习技术来构建DTI的预测模型，因为一种新药的研发到最终投入市场使用需要十年以上的时间而机器学习技术可以降低药物塞选提高研发的效率。

1.4 非技术因素分析

非技术因素直接关系到解决方案的实际应用和社会影响。针对本项目提出的基于卷积神经网络药物靶标相互预测作用，需考虑以下的非技术因素：在社会效益上，本项目有望为药物靶标相互作用预测带来积极的影响。通过特征提取和数据增强，可以更好地满足药物研发的不足，缓解少数据样本问题，提升药物靶标相互预测的效率，提高预测的准确率。接着法律上，在进行药物靶标相互作用的预测研究时，本人仅用于个人学习与研究不涉及到商业用途，也必须遵守相关法律法规，特别是在数据共享和使用方面。

当然对于数据隐私和安全，数据集都是网上公开的数据集，不涉及到个人隐私数据，在数据的处理过程中，遵守相关的数据隐私法规。以及处于对药物靶标的安全考虑在药物靶标相互作用的预测的结果，需要确保预测的准确性和可靠性至关重要。错误的预测可能导致无效或有害的药物进入临床试验，带来安全隐患。因此，我们需要对模型的预测结果进行充分的验证和评估。

综上所述，解决方案的实施需要综合考虑各种非技术因素，确保能够最大程度地保护数据的隐私以及药物靶标的安全考虑，同时尽量减少法律和社会风险。

1.5 论文结构安排

本文共分为六个章节，核心为基于预训练模型的特征提取和数据增强、基于卷积神经网络药物靶标相互预测、实验例证，具体章节结构安排如图

第一章主要介绍了药物靶标相互预测作用的背景及意义，国内外近年来的研究、遇到的问题以及论文结构。

第二章主要介绍了文中涉及的药物靶标相互预测作用的技术和方法的介绍等。

第三章主要介绍了基于预训练嵌入和数据增强的DTI预测。

第四章主要介绍了基于预训练嵌入和数据增强的药物-靶标亲和力预测。

第五章主要介绍了可视化界面的实现。

第六章主要归纳了本文的主要工作和成果，研究中的不足并提出未来研究方向。




图1-1 论文结构示意图

第2章 药物靶标相互预测作用的技术和方法的介绍

2.1 DTI的预测和结合亲和力预测介绍

对于DTI的预测可分为两种一个是预测DTI之间的相互作用和DTI之间的结合亲和力。DTI预测的相互作用是药物和靶标之间能结合，而对于DTI的结合亲和力是药物和靶标之间高亲和代表药物在低浓度和靶标有相互作用。二分类任务的DTI预测是判断药物和靶标中是否有相互作用。定义可以表示为：设药物为D，蛋白质为P，映射函数为 f ：

$$D \rightarrow P \rightarrow \{0, 1\}$$

$$f(d, p) = \begin{cases} 1, & \text{若 } d \text{ 与 } p \text{ 有相互作用} \\ 0, & \text{若无相互作用} \end{cases} \quad (2-1)$$

损失函数为交叉熵损失函数

$$\text{Loss} = -[y \log(p) + (1 - y) \log(1 - p)] \quad (2-2)$$

通过最小化交叉熵损失，模型可以学习到药物和蛋白质之间的相互作用。回归任务的DTI结合亲和力是预测药物和蛋白质之间的结合强度。定义的药物和蛋白质和二分类一样是D和P，映射函数为 g ： $D \rightarrow P \rightarrow \{R\}$ 。R值越高强度越强，所需的量越少就能结合了。损失函数常用的是均方误差MSE：

$$\text{Loss} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (2-3)$$

对应的N是样本数量， y_i 是i的样本的真实结合亲和力， $\hat{y}_i$ 是模型预测的亲和力。

2.2 预训练模型的嵌入

预训练模型的嵌入是自然语言处理等的一个重要的技术，嵌入是将高维度映射到低维度的向量空间。首先，预训练模型是在大规模无标签数据上进行自监督学习并训练后学习了对应的特征并通过微调来将这些特征用在你对应的下游中，本文就是使用的预训练的模型进行特征提取后作为输入嵌入进我的模型。其次，模型的嵌入是从静态的模型到现在的上下文模型，例如Word2Vec到BERT等。上文文模型主要是依赖Transformer架构，捕捉长距离依赖^[21]。由此可见，预训练嵌入有许多优势，比如自动特征学习就无需手动设置特征提取以及迁移能力可以在多个模型中进行微调以使用对应的模型。

2.3 数据增强技术

数据增强是在原有的数据集上通过扩大和多样性，这些变化可以是几何变化，颜色变换、噪声添加等等。使用了数据增强可以提神模型泛化能力和鲁棒性。^[22]在早起的应用中，研究人员使用翻转，缩放，旋转等来实现数据的多样性，近年来，随着深度神经网络的崛起，数据增强得到了进一步的发展，2019年提出了AutoAugment学习方法，进一步优化了数据增强策略，使得数据增强不仅限于简单的几何变换而是显著提升了模型在小数据集上的表现^[23]。总的来说，数据增强可以缓解小数据上容易过拟合的问题来提升模型的泛化能力。^[24]

2.4 MCANet模型的原理

本文首先介绍MCANet，一种基于共享多头交互注意力机制的药物靶标相互预测作用模型。该模型由Jian Bian^[25]等提出，主要用于精准预测药物与靶标之间的相互作用是个二分类的模型，可以帮助减少药物开发的周期。

2.4.1 输入设置

MCANet的模型的药物输入是采用的SMILES序列进行输入，将SMILES序列将每个字符转换成对应的独立的标签共有64个，则每一个被分配了1到64的整数，将SMILES字符到索引的映射字典，将SMILES字符串转换为数值向量表示。由于每一个SMILES的序列长度都不一样，MCANet对短的SMILES序列进行了填充为0，对于长的SMILES进行了截断，最大长度为100。

蛋白质的输入采用的是由氨基酸序列组成的输入，将氨基酸转换成每个字符对应的每个独立的25个字符，将每一个的序列字符到索引的映射字典，将蛋白质序列字符串转换为数值向量表示。由于每个蛋白质的长度都不统一，所以对于短序列的蛋白质进行填充为0，而对于过长的蛋白质进行截断，蛋白质最大长度为1000。

2.4.2 构建模型

MCANet是一个共享权重的多头交叉注意力机制的预测模型，专门解决药物-靶标相互作用预测设计。该模型是由两个CNN分别对药物和蛋白质进行特征提取提取到低维特征表示。得到两者的特征序列表示后传入共享权重的多头交叉注意力模块并将药物和蛋白质的交互特征通过全局最大池化。最后再将拼接后的特征输入到一个全连接网络进行最后的预测。具体模型如下:在标签编码之后通




图2-1 MCANet流程图

过嵌入层生成药物和蛋白质的嵌入矩阵后，使用两个CNN分别提取两者的低维特征，药物的CNN卷积核大小分别为4、6、8，每个卷积层后接ReLU激活函数。蛋白质的卷积核大小分别为4、8、12，同样每个卷积层后接ReLU激活函数。

MCANet核心的是使用了共享权重的多头交叉注意力机制，减少了参数量以提高模型的效率并实现了双向的交互。多头注意力机制可以让模型从多个角度来观察药物和蛋白质，可以更有效的捕获药物和蛋白质的特征，而对于交叉注意力机制通过药物作为查询，蛋白质作为键和值和蛋白质作为查询，药物作为键和值可以有效的捕获药物之间的复杂关系。共享权重也可以更好的提升模型的泛化能力，避免了因参数过多而导致的过拟合问题。为了缓解类别不平衡和过拟合，MCANet使用了PolyLoss。PolyLoss是个灵活且高效的损失函数，能够显著提升模型的性能和泛化能力。以及PolyLoss通过正则化效应，降低模型对噪声或异常样本的敏感性，从而减少过拟合，因为PolyLoss能够增强对少数类的关注，减少对多数类的过度拟合。如公式所示：

$$\text{Poly} - N = -\log P_i + \sum_{i=1}^N \epsilon_i (1 - P_i)^i \quad (11)$$

随后，再将药物和蛋白质分别通过最大池化层后拼接成一个统一的特征向量。最后，输入到全连接层，经过Dropout和LeakyReLU激活函数最终输出药物-靶标相互作用的预测概率。本研究采用了MCANet作为研究的基础，了解

药物-靶标相互作用预测的核心问题，并在此基础上进行创新与优化。主要对药物编码嵌入方法和数据预处理部分。针对药物编码的嵌入采用了预训练模型的特征提取作为嵌入，旨在用更为精准且全面的方式捕捉药物分子的复杂结构特征和化学属性。针对数据预处理的部分是用了数据增强来解决小数据的过拟合。

2.5 DeepDTA模型的原理

本文介绍的DeepDTA模型，是一个基于深度学习模型的药物靶标结合亲和力预测，由Öztürk et al.^[18]等人提出的，主要目标是预测药物与靶标蛋白之间的结合亲和力。结合亲和力是个连续的值，通常是以CI，Kd值等来表示。相对于MCANet的二分类模型，DeepDTA提出的是个回归模型，不会忽略结合亲和力，因为结合亲和力是反映药物与靶蛋白之间相互作用强度，抑制常数（ K_i ）表示抑制剂与酶或受体结合的亲和力，数值越小，亲和力越强；解离常数（ K_d ）衡量配体与靶标之间结合的稳定性，数值越小，表示结合越紧密；半数抑制浓度（ IC_{50} ）表示药物抑制靶标活性的浓度，数值越小，说明药物的抑制效果越好。

2.5.1 输入设置

DeepDTA采用的无论是药物还是蛋白质，首先经过嵌入表示，然后通过多层1D卷积层提取特征。对于药物的输入是以SMILES字符串形式表示并对SMILES字符串中的每个字符进行标记编码，共有64个字符标签，接着将每个字符映射成128维的向量，为了让药物序列有统一的长度，DeepDTA将药物的最大长度设置为100，对短的序列进行了填充补0，对长序列进行截断。这样的预处理确保了所有药物序列能作为一个定长矩阵输入CNN。

蛋白质则采用的氨基酸序列作为输入，也是对对应的字母进行了标记编码以及自定义的字典，共有25个。对于嵌入层也是和药物一样，索引映射为128的向量空间。对于蛋白质的预处理也是限制了蛋白质的最大长度为1000，对于短序列的蛋白质进行了补0的填充和对于长序列的蛋白质进行截断。

2.5.2 构建模型

DeepDTA采用的是两个个别的CNN进行的特征提取，对于药物和蛋白质是独立的CNN个别学习对应的特征，分别从SMILES和蛋白质序列的嵌入矩阵输入到对应的CNN中。然后将药物和蛋白质的特征向量拼接在一起，形成一个统一的特征向量后传入全连接层并会输出一个连续值，表示药物与靶标的结合亲和力。具体模型如下：

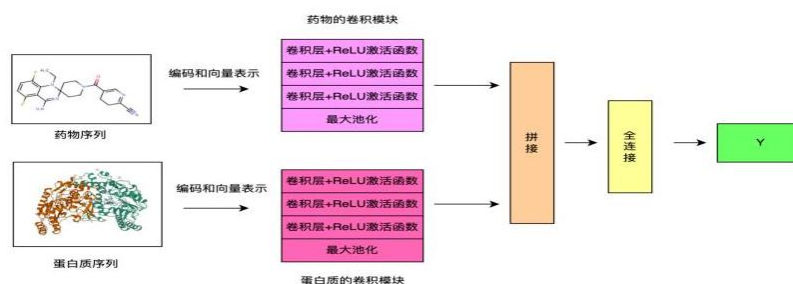


图2-2 DeepDTA流程图

两个CNN模块分别为药物的3个卷积层大小为4，6，8，每个卷积层后接ReLU激活函数，增加非线性。而对于蛋白质的卷积层大小为4，8，12，同样每层也是接了ReLU激活函数。接着都接入了最大池化层并进行特征拼接再通过三个全连接层1024，1024，512神经元和前两个带Dropout 0.1，设置了两个Dropout来防止过拟合。最后输出层预测结合亲和力。

该模型的损失函数使用的是MSE损失函数，优化器方面是使用的Adam优化器，学习率设置为0.001以及100个遍历和256的批大小。对应Adam优化器的好是收敛速度快，训练效率高。该模型选择了MSE损失函数是因为它计算预测值与真实值之间的平方差平均值和MSE惩罚较大的预测误差，引导模型尽量接近真实结合亲和力值，其公式如下：

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad \Sigma n \quad (2-4)$$

本研究采用了DeepDTA的模型作为研究，了解药物-靶标相互作用预测的核心问题，并在此基础上进行创新与优化。主要对药物编码嵌入方法和数据预处理部分。针对药物编码的嵌入采用了预训练模型的特征提取作为嵌入，旨在用更为精准且全面的方式捕捉药物分子的复杂结构特征和化学属性。针对数据预处理的部分是用了数据增强来解决小数据的过拟合。针对相互作用建模采用基于多头自注意力模型的药物-靶标相互作用预测方法，能够有效地捕捉药物和蛋白质之间的相互作用和复杂性，提升模型的泛化能力。回归任务输出的是个连续值并保留了亲和力的强弱程度。

第3章 基于预训练嵌入和数据增强的DTI预测

本章主要介绍的预训练嵌入和数据增强以及共享多头交互注意力机制，并展示了如何将SMILES序列和蛋白质序列进过预训练模型来进行特征提取后嵌入进CNN模块。将新的嵌入方式与MCANet的方法进行实验的对比。为了解决无嵌入的特征提取方法，本文提出了基于预训练的模型进行特征提取的嵌入。在此期间为了解决小样本的问题，本文提出了基于数据增强来解决少样本的数据集和缓解过拟合问题。

3.1 预训练嵌入

预训练嵌入是使用的预训练的模型进行特征提取后迁移到下游任务进行对应的操作，用预训练模型在大规模数据中学习到的通用特征。早起的嵌入是使用的Word2Vec，通过Skip-Gram模型，利用局部上下文预测目标词，缺点是仅依赖局部上下文，缺乏全局语义理解和同一词在不同语境中向量不变。现有的模型是基于上下文的动态向量表示，同一词在不同语境中有不同嵌入也是动态嵌入，比如BERT模型使用的是基于双向Transformer编码器，通过掩码语言模型和下一句预测任务来捕捉全局上下文信息也是成为NLP任务的标准流程使用的预训练+微调模型。^[26]

3.1.1 药物的预训练嵌入

首先对于药物的预训练模型嵌入，本文使用的ChemBERTa-77M-MLM是RoBERTa模型针对化学分子来学习的，它在7700万个来自PubChem的唯一SMILES字符串上进行了预训练，使用了掩码语言模型MLM作为预训练目标^[27]。该模型的隐藏层维度为384，12头交互注意力，3层的隐藏层和词汇表为591。12个交互注意力可以有效的从多个角度来捕获SMILES的化学性质。ChemBERTa的分词器基于BPE方法和嵌入分词后的标记会被映射到一个连续的向量空间，能够有效地分解SMILES表达式，同时保留其化学结构的语义信息。SMILES的序列例如用的"CCO"来表示：分词结果为["C", "C", "O"]而"CCL"分词结果为["C", "CL"]。分词后的标记通过嵌入矩阵映射为高维向量，ChemBERTa使用一个嵌入矩阵，不仅表示每个token的静态特征，还通过多头注意力机制捕获了分子全局的上下文关系，使得模型能够对SMILES表示中的重要子结构及其相互作用进行建模。

3.1.2 蛋白质的预训练嵌入

蛋白质的预训练模型的嵌入，本文使用的Prot-T5-XL-Uniref50是一种基于T5架构的预训练模型。它在4500万个来自UniRef50的蛋白质序列上进行了预训练，使用了Bart-like的掩码语言模型（MLM）作为预训练目标。该模型在

训练中是用了单个空格和21个词汇量进行标记。稀有氨基酸“U、Z、O、B”被映射到“X”。预处理步骤是动态进行的，通过切割和填充蛋白质序列直至512个标记。预训练过程中，随机选择15%的氨基酸进行掩蔽。80%的被掩蔽氨基酸替换为特殊标记[MASK]。10%的被掩蔽氨基酸替换为随机的标准氨基酸。10%的被掩蔽氨基酸保持不变。掩蔽策略的设计灵感来自于自然语言处理中的BERT模型，帮助模型学习上下文信息从而提高对被掩蔽氨基酸的预测能力。在蛋白质序列建模中，采用类似的掩蔽策略有助于模型捕捉序列中的生物学特征和结构信息。

3.2 数据增强

由于药物靶标的数据集十分的稀缺，因此对于小数据存在的问题和使用CNN进行二次特征提取容易使模型过拟合。过拟合是对于小数据集上常发生的事，为了解决模型容易过拟合以及小数据数据稀缺的问题，我们引入了数据增强。数据增强是对原有的数据进行旋转，替换，缩放等。

3.2.1 药物的数据增强

首先对于药物化合物可以有多个不同顺序的SMILES字符串表示，通过生成等价的但是顺序不同的SMILES，增加了SMILES的多样性但不改变化学意义。利用RDKit化学库提供的SMILES功能生成等价的随机SMILES，分子结构相同，但原子编号顺序不同，使用的其中触发随机原子排序。RDKit是一个开源的化学信息学和机器学习软件工具包，它为化学和药物研发领域提供了丰富的功能和工具，被广泛应用于化合物的表示。

3.2.2 蛋白质的数据增强

蛋白质的数据增强对每个蛋白质序列的氨基酸以0.01的概率随机替换为20种标准氨基酸的其中一种并生成新的蛋白质序列。例如标准氨基酸（A, C, D, E, F, G, H, I, K, L, M, N, P, Q, R, S, T, V, W, Y）这些将原始的氨基酸替换成新的氨基酸。0.01的随机概率也是100个氨基酸中会有1个被替换成另一种随机氨基酸，突变率控制了增强的强度和多样性，过高的突变率可能导致产生不自然的序列，而过低的突变率则可能增加的多样性较少，效果不明显。蛋白质的序列长度还是一样保持不变，只是替换了其中的1个氨基酸。蛋白质在自然界中也会发生突变，由于基因突变、转录和翻译过程中的错误以及环境压力，蛋白质序列会发生一定程度的变化，虽然大多数的突变并不会影响蛋白质的功能。[28]

为此我们提出了一种基于预训练嵌入和数据增强的方法，对药物和蛋白质序列使用预训练模型进行特征提取后作为嵌入输入以及对数据集进行数据增强，使用RDKit对药物进行数据增强和对于蛋白质序列则替换单个氨基酸的序列。

3.3 模型

本文使用的模型是2个独立的药物和蛋白质的CNN模块以及双向多头交叉注意力机制。




图3-1 MCANet+PA的模型框架

3.3.1 卷积神经网络

对于CNN模块，本文使用了两个独立的CNN模块，药物的嵌入是由三个意维卷积层组成，药物卷积核的大小为4，6，8。输入形状修改成适合1维卷积的形状经过3层卷积核，使用最大池化层将序列长度压缩为1。对于蛋白质的卷积核大小为4，8，12，其他的步骤和药物一致，也是修改了形状后经过卷积核并使用最大池化。

药物的第一层输入为药物位置的嵌入维度，输出的过滤层为16，卷积核为4后接批归一化和ReLU激活函数。第二层，输入是过滤层为16，输出是2倍的过滤层为32，卷积核大小为6，使用的批归一化和ReLU激活函数。第三层，输入的是2倍的过滤层为32，输出为4倍的过滤层64，卷积核大小为8，接的批归一化和ReLU激活函数。

蛋白质的第一层输入为蛋白质的嵌入维度，输出是过滤层为16，卷积核为4后接入批归一化以及ReLU激活函数。第二层的输入过滤层为16，输出是2倍的过滤层32，卷积核大小为8接的批归一化和ReLU。第三层输入过滤层为32，输出为过滤层为64，卷积核为12接的批归一化和ReLU激活函数。

3.3.2 双向多头交叉注意力机制

双向多头交叉注意力机制的核心思想是多头注意力和通过让药物特征和蛋白质特征相互作为查询（Query）、键（Key）和值（Value）来实现双向的信息融合，通过多头注意力机制来捕捉药物和蛋白质相互作用的多方面特征。每个注意力头独立计算权重，最终通过线性变换融合多头结果。注意力计算公式为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (3-1)$$

Q, K, V分别为查询，键，值的矩阵， d_k 是键的维度，用于防止数值过大以及使用softmax按行归一化注意力分数。对于多个头注意力机制，每个头独立计算注意力，然后将结果拼接并通过线性变换输出。其公式为：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h)W^O \quad (3-2)$$

每一个单头为公式：

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (3-3)$$

W_iQ 是查询的投影，映射到第*i*个头的子空间和 W_iK 还有 W_iV 一样。 W^O 是输出投影矩阵将所有头的拼接进行线性变换，得到最终的多头注意力输出。

3.4 实验与结果

3.4.1 数据集

本研究使用的数据集是Davis和Kiba数据集作为药物靶标相互预测作用的数据集，Davis数据集包含68种药物和379种蛋白靶标，共有25,772个相互作用对，数据密集，适合全面评估模型。Kiba数据集包含2068种药物和225种靶标，116,350个相互作用对，数据较大且稀疏，反映现实场景。

表3-1 数据集信息

数据集	蛋白质	药物	相互作用	训练集	测试集
Davis	379	68	25772	20617	5155
KIBA	225	2068	116350	93080	23270

3.4.2 药物基于预训练嵌入和数据增强

从Davis数据集读取每一行的数据化合物ID, 蛋白质名称, SMILES序列, 蛋白质序列, 标签, 存储为字典的形式后提取对应的SMILES序列和使用了集合来去重并转换成列表。此外, 还移除每行首尾空白。接着使用预训练模型ChemBERTa-77M-MLM模型来进行预训练的特征提取, 对SMILES序列进行分词, 填充短序列和截断多余部分后生成嵌入并设置药物的最大长度是100。为了减少内存的调用, 本文使用了无需计算梯度并设置了模型的评估方式, 只是需要进行嵌入并不需要进行训练。该模型使用的包含了last hidden state是token级别的嵌入。

本文选择了使用last hidden state对比与pooler output, 因为last hidden state输出的是一个二维矩阵包含了 $\text{batch_size} \times \text{sequence_length} \times \text{embedding_dim}$, 其中: batch_size是批量大小, sequence_length是序列长度, embedding_dim是嵌入维度。而对于pooler output输出的是也是个二维包含了 $\text{batch_size} \times \text{hidden_size}$, 其中的batch_size是批量大小, hidden_size是隐藏层维度。前者是last hidden state的输出适合CNN的嵌入, 而对于pooler output的话只有两个输出, CNN的输入需要批量大小, 序列长度, 嵌入维度, 所以这里使用的是last hidden state因为可以作为CNN的输入。

最后数据增强是一种通过对现有数据应用各种变换来增加训练集大小和多样性的技术, 对于小数据集容易过拟合, 所以使用数据增强可以很好的防止模型过拟合。首先, 我们使用RDKit将SMILES转换为一个随机的SMILES, 同一个分子字符的顺序的合法SMILES, 通过RdKit验证其有效性, 只有合法的才加入数据集, 模型可以学到与具体字符串序列无关的结构特征, 这有助于防止模型过拟合于某一种SMILES写法。新样本使用相同的药物的索引, 标签保持不变, 使用相同的药物索引对于不同的SMILES是同一药物的多种表示形式, 模型能学习到分子表示的不变性, 而不是过分依赖特定的SMILES写法。通过设置augment factor来控制随机生成的SMILES, 例如设置为2原始的SMILES生成一个增强的SMILES, 通过循环达到了2个SMILES数据。

3.4.3 蛋白质基于预训练嵌入和数据增强

从KIBA数据集读取每一行的化合物ID, 蛋白质名称, SMILES序列, 蛋白质序列, 标签, 存储为对应的字典并提取对应的蛋白质序列。对于数据的预处理这里使用了集合来去重并转换成列表, 还移除每行首尾空白。接着使用的预训练模型Prot-T5-XL-Uniref50来进行预训练的特征提取, 对蛋白质序列进行分词, 填充短序列和截断长序列, 最大的序列为1000并生成嵌入。为了减少内存的调用, 本文使用了无需计算梯度并设置了模型的评估方式, 只是需要进行嵌入并不需要进行训练。并且本文也使用了正则表达式将序列中的稀有或模糊氨基酸(U、Z、O、B)替换为X并将处理后的字符串转换为字符列表和在每个氨基酸之间插入空格, 方便后续的分词操作。该模型使用的包含了last hidden state是token级别的嵌入。本文选择了使用last hidden state对比与pooler output和药物的一样使用的last hidden state, 因为pooler output的形状不适合作为CNN的嵌入。

在自然界中, 蛋白质会发生点突变, 即一个氨基酸被替换成另一个, 常见于进化、疾病变异、实验误差等。所以我们本文引入了数据增强方面对于蛋白质的突变, 我们使用的用20个种氨基酸中随机选取一个替换当前氨基酸, 设置氨基酸突变率为0.001就是表示每个位置的氨基酸被替换的概率。突变率设置较小以保持蛋白质序列的大部分生物学功能不变并且只引入少量变化从而增加数据多样性而不至于引入太多噪声。适当的进行蛋白质的突变可以提高模型的泛化能力。

3.4.4 评估指标

为了验证所提出方法的性能，本文采用了分别为：准确率，精确率，召回率，F1，ROC曲线下面积，PRC。主要的是基于混淆矩阵来计算，混淆矩阵有四种组合如真阳性TP真实样本为1预测标签为1，假阳性FP真实样本为0预测标签为1，真阴性TN真实样本为0预测标签为0，假阴性FN真实样本1预测为0。

本文采用了准确率所有预测中正确比例的指标，衡量模型整体正确率，其公式为：

预测 \ 真实	0	1
	0	1
0	真阴性	假阴性
1	假阳性	真阳性

图3-2 混淆矩阵

$$Accuracy = \frac{\text{真阳性} + \text{真阴性}}{\text{总样本数}} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3-4)$$

当然本文还是用了精确率用来衡量模型预测真的正类，其公式为：

$$Precision = \frac{\text{真阳性}}{\text{预测为正类的样本数}} = \frac{TP}{TP + FP} \quad (3-5)$$

其中的TP为真实为正样本且预测为正的样本数，FP为真实为负样本但预测为正的样本数

除此之外，本文还采用了召回率若只单靠模型的准确率容易让模型倾向少报正类，实际正样本中被正确预测的比例用来衡量模型找到所有正样本的能力，其公式为：

$$Recall = \frac{TP}{TP + FN} \quad (3-6)$$

值得注意的是本文还采用了F1 Score来调准确率和召回率，其公式为：

$$F_1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (3-7)$$

同时本文也使用了ROC曲线下面积（ROC-AUC）用于衡量模型的性能，ROC以横轴为假阳性率（FPR）而纵轴为真阳性率（TPR）。AUC则曲线下面积，它的取值范围是[0, 1]，AUC越接近1模型性能越好，AUC=0.5模型在随机猜测，AUC<0.5则模型性能差于随机。其公式如下：

$$AUC = \int_0^1 TPR(FPR^{-1}(x)) dx \quad (3-8)$$

最后，本文还是用了平均精确率（PRC）是二分类中重要的评估方法，通过精确率-召回率曲线来反应了Davis以及KIBA这种不平衡类别的数据集。

$$AP = \frac{\sum_n (R_n - R_{n-1}) P_n}{\sum_n} \quad (3-9)$$

Pn: 第n个点的精确率，Rn: 第n个点的召回率，Rn-Rn1是前一个阈值的召回率。PRC的取值的范围从0到1，越接近1模型的效果越好越能识别正样本。

3.4.5 实验设置

实验设置的超参数，比如学习率，卷积层，批次大小等等。通过选定最佳组合来对测试集进行训练。在实际验证中，过滤器的数量为16，化合物的卷积核为4，6，8以及蛋白质的卷积核为6，8，12取得了最好的结果。因此，最终实验中采用该组合作为模型的超参数配置。过程中其他固定的参数见表下：实验过程中使

表3-2 实验参数设定

参数	Davis	KIBA
epoch	200	200
batch size	128	32
dropout	0.5	0.5
learning rate	0.001	0.001
optimizer	AdamW	AdamW
num head	8	8
d_k	64	64
hidden neurons	1024, 512, 2	1024, 512,
k folds	5	5
patience	7	7

用了PyTorch作为开发框架，Pytorch框架拥有良好的性能和便捷性于提升实验的效率。PyTorch提供了高效的张量运算和CUDA支持，能够充分的使用GPU加速进行训练。训练环境是如表。在实验过程中，我们借助了GPU的高并行计

表3-3 训练环境

类别	参数
系统	ubuntu22.04
GPU	vGPU-32GB
CPU	12 vCPU Intel (R) Xeon(R) Platinum 8352V CPU @ 2.10GHz
CUDA	12.4
框架	PyTorch 2.5.1
Python	3.12

算能力，大幅提高了模型训练的速度，尤其是在处理大规模数据集和复杂模型架构时，显著缩短了实验周期。对于数据集本文将数据集被分为80%的训练集和20%的测试集，确保测试集是用于最终的模型评估，完全独立于交叉验证过程，不参与模型训练或验证，训练集进行5折的交叉验证是将数据集分成5分，选1折为验证集，4折为训练集。为了防止模型的过拟合，实验采用5折交叉验证并通过早停机机制并设置了耐心等待值为7。如图所示：






图3-3 数据集划分

3.4.6 实验结果

本章中提出了基于预训练嵌入和数据增强的DTI预测，利用本章提出的方法对Davis和Kiba数据集进行训练，并于MCANet比较，最终得到了以下结果：

表3-4 不同模型的实验结果

数据集	模型	Accuracy	Precision	Recall	AUC	PRC	F1
KIBA	MCANet-B	0.9168	0.7889	0.7764	0.9504	0.862	0.8588
	MCANet+PA	0.9447	0.837	0.8817	0.9783	0.9274	
Davis	MCANet-B	0.8927	0.8265	0.7876	0.9487	0.8943	0.9012
	MCANet+PA	0.9425	0.8809	0.9226	0.9799	0.9584	

如表所示在Davis和Kiba数据集上本实验提出的模型的指标都分别的超越了MCANet-B。对于Kiba数据集，准确率提升了0.0279，精确率提升了0.0481，召回率提升了0.1053。相对于Davis数据集则准确率提升了0.0461，精确率提升了0.0438，召回率提升了0.1347。由此可见在本次实验里，MCANet+PA在Accuracy、Precision、Recall、AUC和PRC等指标上均超越了MCANet-B，在Recall和PRC上的显著提升。这对于药物发现具有重要意义，能够更高效地筛选潜在候选药物，加速研发进程。综上所述，MCANet+PA模型通过融合预训练表示与多样化的数据增强策略，在多个数据集和评价指标上取得了全面优越的性能。

这两个模型中，训练集和验证集上的损失都随训练周期的增加而减少和为了防止过拟合，本文当使用了Dropout 0.5和早停机制耐心等待值为7来缓解模型的过拟合。




图3-4 Davis二分类的5-Fold预测效果图




图3-5 Kiba二分类的5-Fold预测效果图




图3-6 Davis数据集上的5-Fold分类性能指标可视化




图3-7 KIBA数据集上的5-Fold分类性能指标可视化

第4章 基于预训练嵌入和数据增强的药物-靶标亲和力预测

对于靶标相互预测作用大多数都是二分类问题，而二分类问题忽略了相互作用强度的连续性。本章主要介绍的预训练嵌入和数据增强以及共享多头交互注意力机制，并展示了如何将SMILES序列和蛋白质序列经过预训练模型来进行特征提取后嵌入进CNN模块。将新的嵌入方式与DeepDTA的方法进行实验的对比。为了解决无嵌入特征提取，本文使用了基于预训练的模型进行特征提取的嵌入。其中，为了解决小样本的问题，本文使用了基于数据增强来解决少样本的数据集和缓解过拟合问题。

4.1 预训练嵌入

对于预训练模型的嵌入是指模型在大数据中生成的特征表示，捕获了大量的词汇或者药物之间的语义关系等等。在NLP中，BERT模型能将单词映射到高维空间，使得语义相似的单词更接近。预训练模型可以学到通用的特征，方便我们迁移到其他模型上因此会有更好的泛化能力。预训练模型可以更高效的学习，减少模型从头开始学习的时间和资源消耗。^[29]

4.1.1 药物的预训练嵌入

ChemBERTa-77M-MLM是一个针对化学分子学习的RoBERTa模型，基于7700万个来自PubChem的唯一SMILES字符串进行预训练，采用掩码语言模型(MLM)作为预训练目标。该模型具有384维的隐藏层、12个交互注意力头和3层隐藏层。ChemBERTa专门针对化学分子能够捕捉化学结构的语义信息和分子性质。相比通用NLP模型它更适合处理药物分子表示任务。PubChem数据集提供了丰富的化学分子信息，ChemBERTa能够从中学习到SMILES字符串的语法和语义，帮助模型更好地理解药物的结构和性质，微调需少量数据。

4.1.2 蛋白质的预训练嵌入

本文使用的Prot-T5-XL-UniRef50是基于T5 (Text-To-Text Transfer Transformer) 架构开发该模型在UniRef50数据库中约4,500万个蛋白质序列上进行预训练。通过大规模且多样化的蛋白质序列数据，Prot-T5-XL能够有效地学习并提取蛋白质序列中的生物学和结构特征，形成泛化性强的序列嵌入。该模型采用了MLM的掩码语言模型来进行训练，通过掩蔽氨基酸残基的方式，迫使模型预测原始序列中的掩蔽位置。具体而言，预训练过程中随机选择蛋白质序列中15%的氨基酸进行掩蔽。80%的被掩蔽氨基酸替换为特殊标记[MASK]。10%的被掩蔽氨基酸替换为随机的标准氨基酸（不同于原始氨基酸）。10%的被掩蔽氨基酸保持不变。掩蔽策略的设计灵感来自于自然语言处理中的BERT模型，旨在帮助模型学习上下文信息，提高对被掩蔽氨基酸的预测能力。该模型在训练中是用了单个空格和21个词汇量进行标记。稀有氨基酸“U、Z、O、B”被映射到“X”。预处理步骤是动态进行的，通过切割和填充蛋白质序列直至512个标记。

4.2 数据增强

由于本文使用的是小数据集，容易导致模型在训练中过拟合，所以才使用了数据增强来缓解过拟合，增强模型对未见数据的泛化性能。数据增强也可以很好的解决数据稀疏性的问题，在样本量有限或分布不均匀的情况下，生成新样本以缓解数据不足的问题。数据增强是通过生成新的训练样本，增加数据的多样性，随机化SMILES和蛋白质突变模拟真实变异，提升模型鲁棒性。

4.2.1 药物的数据增强

首先对于药物的增强，本文使用的RDKit将SMILES字符串随机化，生成等价的分子表示。同一分子可以有多种SMILES表示形式，通过随机化可以生成这些等价表示，增强因子为2。

4.2.2 蛋白质的数据增强

蛋白质的增强，本文通过设置突变率为0.001对蛋白质序列进行随机突变，例如将一个氨基酸替换为其他氨基酸，模拟自然变异，增强因子为2。

4.3 模型

本文的模型是个回归模型，使用的2个独立的CNN和共享双向注意力机制。这种设计能够有效地处理药物和蛋白质的序列数据，并通过注意力机制强化它们之间的相互关系，从而提升模型的性能。CNN被广泛用于序列数据的特征提取，在生物信息学中用于处理药物和蛋白质序列，而双向注意力机制则能够捕捉到更加复杂的相互依赖关系。




图4-1 DeepDTA+PA的模型框架

4.3.1 CNN

本文使用的是两个单独的CNN模块分别为药物的4, 6, 8, 蛋白质的4, 6, 12。药物和蛋白质通过一维卷积神经网络（CNN）从药物嵌入中再次进行提取特征并使用三层卷积结构在每层后接批归一化和ReLU激活函数。设置了池化层对CNN输出的特征图进行一维最大池化，减少序列维度。最后到全连接层使用的是三层的全连接层，中间加入LeakyReLU激活函数和Dropout防止过拟合。全连接层的功能是将药物和蛋白质的特征融合并降维，最终输出一个标量值。

Leaky ReLU是一种激活函数，是对传统ReLU激活函数的改进。ReLU的公式：

$$\text{ReLU}(x) = \max(0, x) \quad (4-1)$$

Leaky ReLU改进了这一点，允许在 $x < 0$ 时输出一个小的非零值，而不是完全为0。其数学公式为：

$$\text{Leaky ReLU}(x) = \begin{cases} x & \text{if } x > 0 \\ \alpha x & \text{if } x \leq 0 \end{cases} \quad (4-2)$$

α 是一个小的正数（通常默认值为0.01），称为泄漏系数。

使用LeakyReLU可以很好的解决在ReLU中，如果某个神经元的输入始终 $x \leq 0$ ，其输出和梯度都为0。这会导致该神经元的权重在反向传播中无法更新。而对于LeakyReLU可以很好的解决，通过在 $x < 0$ 时引入 αx （其中 $\alpha > 0$ ），Leaky ReLU确保梯度不为0（梯度为 α ），使神经元能够继续参与训练。






图4-2 LeakyReLU

4.3.2 共享注意力机制

共享注意力机制是基于多头注意力机制进行扩展，多头注意力机制可以从不同的头计算并学习多个空间或者角度并且参数是共享的，可以很大的减少参数占用的内存。

注意力机制的核心是用了查询，键和值来为每个查询分配权重，从而聚焦于最重要的信息。公式为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (4-3)$$

Q, K, V分别为查询，键，值是输入表示。dk是K的维度，用于缩放点积以避免数值过大。

上面是单个注意力机制，对于多头注意力机制是将输入分成多个头，每个头独立计算注意力，然后将结果拼接并线性变换。

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h)W^O \quad (4-4)$$

每一个单头为公式：

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (4-5)$$

WiQ 是查询的投影，映射到第i个头的子空间和WiK 还有WiV 一样。WO是输出投影矩阵将所有头的拼接进行线性变换，得到最终的多头注意力输出。

共享权重两次计算都使用同一个注意力模块。当药物作为查询时蛋白质作为键和值，不然则相反当蛋白质作为查询时药物作为键和值。两次注意力计算共享同一套权重参数。通过共享参数，模型不仅减少了参数量和计算复杂度，还降低了过拟合风险，同时能够有效捕捉药物与蛋白质之间的对称交互关系。

4.4 实验与结果

本文的实验使用的数据来自是Davis和Kiba数据集。Davis数据集的药物是68个，蛋白质是379个，相互作用是30056。对于Kiba数据集药物是2068，蛋白质是229，相互作用是118254。Davis的亲合力是以Kd值，单位为nM纳摩尔，Kiba的是Kiba Score是个综合得分是由Tang et al^[30]提出，通过整合多种生物活性数据IC50、Ki、Kd计算得出。

表4-1 数据集信息

数据集	蛋白质	药物	相互作用	训练集	测试集
Davis	379	68	30056	24044	6012
KIBA	229	2068	118254	94603	23651

衡量相互作用的关键指标为Kd值是解离常数，指示了药物与靶标之间的结合强度，公式为：

$$pK_d = -\log_{10}\left(\frac{K_d}{1e9}\right) \quad (4-6)$$

4.4.1 药物基于预训练嵌入和数据增强

首先，从Davis数据集读取每一行的数据化合物，蛋白质，亲和力，存储为字典的形式后提取对应的SMILES序列和使用了集合来去重并转换成列表。此外，还移除每行首尾空白。接着，使用预训练模型ChemBERTa-77M-MLM模型来进行预训练的特征提取，对SMILES序列进行分词，填充短序列和截断多余部分后生成嵌入，设置药物的最大长度是100，确保药物的长度统一。为了减少内存的调用，本文使用了无需计算梯度并设置了模型的评估方式，仅进行前向传播以生成嵌入向量，避免训练过程中的参数更新。该模型使用的包含了last hidden state是token级别的嵌入。

本文选择了使用last hidden state对比与pooler output，因为last hidden state输出的是一个二维矩阵包含了batch_size × sequence_length × embedding_dim。

batch_size是批量大小，sequence_length是序列长度，embedding_dim是嵌入维度。

而对于pooler output输出的是也是个二维包含了batch_size x hidden_size，其中：batch_size是批量大小，hidden_size是隐藏层维度。前者是last hidden state的输出适合CNN的嵌入，而对于pooler output的话只有两个输出，CNN的输入需要批量大小，序列长度，嵌入维度。Pooler output的扁平化特征丢失了序列位置信息，因此本研究选择Last Hidden State作为分子结构的嵌入表示。

数据增强的实现借助了RDKit工具包完成，将SMILES转换为一个随机的SMILES在同一个分子字符的顺序的合法SMILES，从而在不改变分子实际结构的前提下可以创造多样化的字符串表示。通过RdKit验证其有效性，只有合法的才加入数据集。模型可以学到与具体字符串序列无关的结构特征，这有助于防止模型过拟合于某一种SMILES写法。当增强因子设为2时，每条原始SMILES将生成1条增强样本是总样本数为原始数据的2倍。通过同一分子的不同SMILES表示，有效降低过拟合风险。

4.4.2 蛋白质基于预训练嵌入和数据增强

从KIBA数据集读取每一行的化合物，蛋白质，亲和力，存储为对应的字典并提取对应的蛋白质序列。对于数据的预处理这里使用了集合来去重并转换成列表，还移除每行首尾空白。接着使用的预训练模型Prot-T5-XL-Uniref50来进行预训练的特征提取，对蛋白质序列进行分词，填充短序列和截断长序列，最大的序列为1000并生成嵌入，确保蛋白质的统一长度。为了减少内存的调用，本文使用了无需计算梯度并设置了模型的评估方式，仅进行前向传播以生成嵌入向量，避免训练过程中的参数更新。

数据的预处理清洗，本文也使用了正则表达式将序列中的稀有的氨基酸（U、Z、O、B）替换为X并将处理后的字符串转换为字符列表和在每个氨基酸之间插入空格，方便后续的分词操作。该模型使用的包含了last hidden state是token级别的嵌入。本文选择了使用last hidden state对比与pooler output和药物的一样使用的last hidden state，因为pooler output的形状不适合作为CNN的嵌入，所以选择了last hidden state以支持后续CNN对氨基酸序列的局部模式学习。

在自然界中，蛋白质会发生点突变，即一个氨基酸被替换成另一个，常见于进化、疾病变异、实验误差等。所以我们本文引入了数据增强方面对于蛋白质的突变，我们使用的用20个种氨基酸中随机选取一个替换当前氨基酸，设置氨基酸突变率为0.001就是表示每个位置的氨基酸被替换的概率，生成新的变异序列。突变率设置较小以保持蛋白质序列的大部分生物学功能不变并且只引入少量变化从而增加数据多样性而不至于引入太多噪声使模型学习到蛋

白质功能的核心特征，而非依赖特定位置的氨基酸残基。

4.4.3 评估指标

为了验证模型的性能，本文使用的MSE，CI，R²_m等验证方式。

MSE是回归模型中最常见的评估方法，衡量模型预测结果与真实值之间的差异。MSE通过计算预测值和实际值之间差异的平方，再取平均值，来评估模型的表现。

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (4-7)$$

n为样本数量，y_i是i个样本的真实值而y_i则是预测值。将每个误差的平方作为惩罚，避免正负误差相互抵消并取平均，得到MSE。

RMSE是均方根误差用于衡量回归预测与真实值的指标，比MSE更直观的反映了预测误差，公式为：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (4-8)$$

n是样本的数量，y_i是i个样本的真实值，y_i是预测值，(y_i-y_i)²是i样本的平方误差

CI是一种排序指标用于衡量预测亲和力的排序与真实的排序，其公式为：

$$CI = \frac{1}{Z} \sum_{i,j: y_i > y_j} h(\hat{y}_i - \hat{y}_j) \quad (4-9)$$

y_i, y_j是真实值，y_i和y_j是预测值，CI的取值范围为0.5到1，越高越表示完美预测，0.5表示的是随机预测，预测值是否正确反映真实亲和力的相对大小。

R²_m是标准的的改。进R²即决定系数，用于衡量魔心解释变量变化的比例，模型预测值与实际值之间的拟合程度，值范围在0到1之间，接近1表示拟合好。

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} \quad (4-10)$$

其中的y_i是实际观察值y_i则是模型预测值y为实际值的均值。

R²忽略了截距的回归决定系数，而R²_m直接考虑预测值与实际值的实际差异，不依赖训练集均值，其公式为：

$$R_m^2 = R^2 \cdot \left(1 - \sqrt{|R^2 - R_0^2|}\right) \quad (4-11)$$

R²是标准决定系数，R²₀是原点回归决定系数，R²_m通过R²和R²₀的差异来评估模型的拟合能力和预测能力，R²_m的值越高模型的预测效果越好并且R²_m在测试集上大于0.5。

皮尔逊相关系数用于衡量DTi与真实值之间的线性一致性，公式如下：

$$r = \frac{\sum_{i=1}^n (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2} \sqrt{\sum_{i=1}^n (\hat{y}_i - \bar{\hat{y}})^2}} \quad (4-12)$$

n为样本数量，y_i为i的样本真实值，y_i是i样本的预测值，y是真实值的均值，y⁻是预测值的均值。越接近1表示预测值和真实值之间高度线性相关，模型预测性能好。

4.4.4 实验设置

实验设置的超参数，比如学习率，卷积层，批次大小等等。通过选定最佳组合来对测试集进行训练。在实际验证中，过滤器的数量为16，化合物的卷积核为4，6，8以及蛋白质的卷积核为6，8，12取得了最好的结果。因此，最终实验中采用该组合作为模型的超参数配置。过程中其他固定的参数见表

表4-2 实验参数设定

参数	Davis	KIBA
epoch	200	200
batch size	128	32
dropout	0.5	0.5
learning rate	0.001	0.001
optimizer	AdamW	AdamW
num head	8	8
d_k	64	64
hidden neurons	1024, 512, 2	1024, 512, 2
k folds	5	5
patience	7	7

实验过程中使用了PyTorch作为开发框架，Pytorch框架拥有良好的性能和便捷性于提升实验的效率。PyTorch拥有灵活和丰富的第三方库，可以直接加载模型并进行微调节省了开发时间。PyTorch业提供了TensorBoard来对训练损失进行可视化操作。训练环境是如表。

表4-3 训练环境

类别	参数
系统	ubuntu22.04
GPU	vGPU-32GB
CPU	12 vCPU Intel (R) Xeon(R) Platinum 8352V CPU @ 2.10GHz
CUDA	12.4
框架	PyTorch 2.5.1
Python	3.12

对于数据集的划分，本文将数据集被分为80%的训练集和20%的测试集，确保测试集是用于最终的模型评估，完全独立于交叉验证过程，不参与模型训练或验证。训练集进行5折的交叉验证是将数据集分成5分，选1折为验证集，4折为训练集。为了防止模型的过拟合，实验采用5折交叉验证并通过早停机制并设置了耐性等待值为7还有Dropout为0.5。

4.4.5 实验结果

本章中提出了基于预训练嵌入和数据增强的DTI预测，利用本章提出的方法对Davis和Kiba数据集进行训练，并于DeepDTA比较，最终得到了

表4-4 不同模型的实验结果

数据集	模型	MSE	CI	R2m	AUPR	RMSE	Pearson
KIBA	DeepDTA	0.194	0.863 (0.002)	0.673 (0.009)	0.788 (0.004)	0.2864	0.9534
	DeepDTA+PA	0.082	0.9364	0.8541	0.9725		
Davis	DeepDTA	0.261	0.878 (0.004)	0.630 (0.017)	0.714 (0.010)	0.3962	0.932
	DeepDTA+PA	0.157	0.9435	0.8099	0.9471		

如表所示在Davis和Kiba数据集上本实验提出的模型的指标都分别的超越了DeepDTA。对于Kiba数据集，均方误差减少了0.112，一致性指数提升了0.07， R^2_m 提升了0.1811，AUPR提升了0.1845。相对于Davis数据集则均方误差减少了0.104，一致性指数提升了0.655， R^2_m 提升了0.1799，AUPR提升了0.2331。由此可见在本次实验里，DeepDTA+PA在MSC，CI， R^2_m ，AUPR等指标上均超越了DeepDTA，在 R^2_m 和AUPR上的显著提升。这对于药物发现具有重要意义，能够更高效地筛选潜在候选药物，加速研发进程。综上所述，DeepDTA+PA模型通过融合预训练表示与多样化的数据增强策略，在多个数据集和评价指标上取得了全面优越的性能。这两个模型中，训练集和验证集上的损失都随训练周期的增加而减少和为了防止过拟合，本文当使用了Dropout 0.5和早停机制等来缓解模型的过拟合。




图4-3 Davis结合亲和力5-Fold预测效果图





图4-4 Kiba结合亲和力5-Fold预测效果图






图4-5 Davis数据集上的5-Fold分类性能指标可视化




图4-6 Davis数据集上的5-Fold分类性能指标可视化

第5章 UI可视化界面

本次的可视化界面是基于Dash开发的，通过Dash，用户可以输入药物分子结构和靶点蛋白序列，系统将通过预训练模型进行预测，并实时展示相应的预测结果及相关指标。对于DTI的界面可分为主要的四个方面展开，主页介绍，数据集，DTI，导出预测数据CSV来介绍。

5.1 DTI的首页

DTI的网页是基于Dash来进行开发，首页主要是讲解药物靶标相互预测作用可分为两类：二分类和回归类。目前大多数的深度学习都是二分类的，但是二分类忽略了药物与靶标之间亲和力的连续性，所以本文提出了可预测二分类和亲和力的两个基于预训练嵌入和数据增强的模型。主要是用了PyTorch，RdKit和py3Dmol来实现。PyTorch用于构建和训练深度学习模型，支持GPU加速训练。RdKit用于画出药物的可视化，而py3Dmol则用于在网页中展示3D分子结构的交互式可视化。图片如下：






图5-1 DTI主页

5.2 数据集

数据集使用的Davis和Kiba，两者均为开源数据集也是被广泛用于评估和比较各种预测模型的性能。Davis和Kiba的药物以SMILES的形式呈现而对于靶标是以蛋白质序列来表示，也方便用户进行查找。本文进一步从PubChem数据库中获取了数据集中涉及的化合物信息，并对每个药物分子和蛋白质都构建了对应的2D结构图3D结构模型进行可视化。2D的结构图展示原子连接关系和功能基团，对于3D的结构展示分子的空间构象，但是有些的药物或蛋白质没3D的结构就没显示出来。2D的获取方法使用的sdf文件转换成图片形式再进行展示的，sdf文件使用Pu把Chem提供的每一个CID有对应的2d和3d结构的也是一样的方法。





图5-2 2D和3D的获取方法

药物和蛋白质的可视化界面：

Drug Target Interaction						
List						
Search by Query, PubChem CID, or SMILES						
Query	PubChem CID	Weight (g/mol)	Molecular Formula	Structure 2D	Structure 3D	Predict DTI
CHEMBL118258	1005638	486.5	C ₂₄ H ₂₇ N ₃ O			Predict DTI
CHEMBL44561	10017019	289.13	C ₁₂ H ₈ BrN ₂			Predict DTI
CHEMBL1999484	10022736	381.5	C ₁₉ H ₁₉ N ₃ S			Predict DTI
CHEMBL15982	10024683	412.6	C ₂₄ H ₂₈ O ₅			Predict DTI

图5-3 药物可视化界面

为了加速模型的推理过程，数据集创建了对应的映射就无需重复的计算分子的特征，从而提高推理的速度，对于每个药物和蛋白质，系统从预训练中加载对应的嵌入，如果找不到对应的索引就会使用动态特征提取来进行，速度相对于静态嵌入会比较慢。





(a) 药物可视化界面

(b) 药物 3D 结构

5.3 DTI

DTI是主要的核心模块，提供了让用户输入药物SMILES序列和蛋白质序列并选择对应的数据集比如Davis或者Kiba进行预测。首先判断是否在静态的索引表中如果存在的话就使用静态的嵌入模块，否则的话就使用动态的特征提取嵌入以支持对于未知的样本的预测。对于药物和蛋白质的信息使用的静态获取，要是没在数据集里使用动态中获取药物从PubChem中获取和蛋白质使用的UniProt来获取。在预测药物和蛋白质的同时也将对应的数据写入历史表中，用户可以通过CSV来导出文件。




图5-4 DTI预测界面

5.4 导出预测数据CSV

最后，本网页还可以将用户保存已预测好了的结果也可以选择对应需要导出的数据成CSV文件方便后续的分析。导出的数据分别有药物SMILES序列，蛋白质序列，预测结果。如果对于分析的结果不想要的也可以进行对应的删除。




图5-5 历史预测文件

第6章 总结与展望

6.1 主要研究成果和结论

本文通过研究药物靶标相互预测作用，分析当前药物靶标相互预测作用存在的问题，重新提出了一个基于预训练嵌入和数据增强的方法，并通过多个验证方法和指标计算模型的有效性。本文主要的研究内容如下：

本文深入的研究了药物靶标相互预测作用，发现当前的研究存在一定的局限性，例如小样本数据，特征提取不足，无法捕获长距离等。因此提出了一种基于预训练嵌入与数据增强的药物靶标相互预测作用的方法解决此类的问题。针对与小样本数据问题，提出了对药物和蛋白质都进行了数据增强，该方法将药物通过RdKit生成等价的但是顺序不同的SMILES，增加了SMILES的多样性但不改变化学意义。与此同时，由于不改变化学意义，药物的化学特性和生物活性特征不会受到影响，因此能有效增强模型对药物的泛化能力。针对特征提取的不足，本文使用了预训练的模型对药物和蛋白质个别的进行特征提取并保存学习到的特征进行嵌入。本文使用的神经网络模型，使用了CNN来进行二次的特征提取并使用共享双向的交互注意力机制。利用多头注意力机制从不同的角度来学习药物和蛋白质内部复杂的依赖关系，增强了模型的特征表达能力和鲁棒性。为了验证本文的模型的有效性，还使用了对应的评估方式和可视化界面以及与DeepDTA和MCANet都进行了对比，证明了实验的有效性。

基于上述内容，并对比实验结果，本文得出以下结论：通过预训练模型的嵌入可以加速模型的对于特征提取的不足，直接通过预训练模型的嵌入可以节省许多的时间，从而提高模型的效率对比与传统的特征提取。本文也通过了数据增强来缓解小数据集在复杂的模型上容易过拟合的问题。同时为了让用户和学者有更好的体验，本文还利用了Dash来进行对应的可视化界面以及对应的保存数据。

6.2 展望

本文提出的基于预训练嵌入和数据增强的药物靶标相互预测作用，虽然在实验中得到了一定的效果，但依然有一些问题以及不足的地方需要进一步的提升和完善如：本研究的模型以两个数据集为基础，虽然这两个数据集在DTI预测中具有广泛的应用，但为了提高模型的普适性和准确性，未来研究可以考虑扩展到更多的数据集。在本研究中使用的CNN和共享交互注意力机制可以使用深度学习领域的快速发展来探索更多新的网络架构或优化方法。本研究的模型在用户体验方面还有待提升，对于不在数据集里的数据用户需要等待模型对药物和蛋白质进行实时的预训练特征提取后嵌入和推理，未来的研究将进一步优化以提高用户的使用体验。

参考文献

- [1]国家药品监督管理局. 国家药监局已批准277个创新医疗器械[EB/OL]. 2024[2025-05-16]. <http://www.ccfdie.org>.
- [2]国家药品监督管理局. 2024年度医疗器械注册工作报告书[EB/OL]. 2025[2025-05-16]. <http://www.ccfdie.org>.
- [3]刘晓光, 李梅. 基于深度学习的药物-靶标相互作用预测研究综述[J/OL]. 智能系统学报, 2024, 19(3):494-524. %5Curl%7Bhttps://doi.org/10.11992/tis.202308024%7D. DOI: 10.11992/tis.202308024.
- [4]Cheng T, Hao M, Takeda T, et al. Large-Scale Prediction of Drug-Target Interaction: A Data-

- Centric Review[J/OL]. AAPS Journal, 2017, 19(5): 1264-1275. DOI: 10.1208/s12248-017-0092-6.
- [5]Liao Q, Zhang Y, Chu Y, et al. Application of Artificial Intelligence in Drug-Target Interactions Prediction: A Review[J/OL]. npj Biomedical Innovations, 2025, 2(1):1. DOI: 10.1038 /s44385-024-00003-9.
- [6]Wang Y, Zhang Z, Piao C, et al. LDS-CNN: a deep learning framework for drug-target interactions prediction based on large-scale drug screening[J/OL]. Health Information Science and Systems, 2023, 11(1):42. DOI: 10.1007/s13755-023-00243-w.
- [7]Djeddi W E, Hermi K, Ben Yahia S, et al. Advancing drug - target interaction prediction: a comprehensive graph-based approach integrating knowledge graph embedding and ProtBert pretraining[J/OL]. BMC Bioinformatics, 2023, 24(1):488. DOI: 10.1186/s12859-023-0559 3-6.
- [8]Pushpakom S, Iorio F, Eyers P A, et al. Drug re-purposing: progress, challenges and recommendations[J/OL]. Nature Reviews Drug Discovery, 2019, 18(1): 41-58. DOI: 10.1038/nrd .2018.168.
- [9]Sardana D, Zhu C, Zhang M, et al. Drug repositioning for orphan diseases[J]. Briefings in Bioinformatics, 2011, 12(4):346-356.
- [10]Hu J, Hu S, Xia M, et al. Drug-target binding affinity prediction based on power graph and word2vec[J/OL]. BMC Medical Genomics, 2025, 18(Suppl 1):9. DOI: 10.1186/s12920-024 -02073-5.
- [11]Bagherian M, Sabeti E, Wang K, et al. Machine learning approaches and databases for pre-diction of drug - target interaction: a survey paper[J/OL]. Briefings in Bioinformatics, 2021, 22(1): 247-269. DOI: 10.1093/bib/bbz157.
- [12]Huang K, Fu T, Glass L M, et al. DeepPurpose: a deep learning library for drug - target interaction prediction[J/OL]. Bioinformatics, 2020, 36(22-23): 5545-5547. DOI: 10.1093/bioinformatics/btaa1005.
- [13]李亚茹, 王倩倩, 车超, 等. 《基于药物子结构与蛋白质三维图信息的化合物-蛋白质相互作用预测》 [J/OL]. 《计算机科学》, 2025:1-9. <http://kns.cnki.net/kcms/detail/50.1075.TP.20250401.0955.002.html>.
- [14]Yamanishi Y, Araki M, Gutteridge A, et al. Prediction of drug-target interaction networks from the integration of chemical and genomic spaces[J/OL]. Bioinformatics, 2008, 24(13): i232-i240. DOI: 10.1093/bioinformatics/btn162.
- [15]Jacob L, Vert J P. Protein - ligand interaction prediction: an improved chemogenomics approach[J/OL]. Bioinformatics, 2008, 24(19):2149-2156. DOI: 10.1093/bioinformatics/btn4 09.
- [16]Frey A. Predicting novel drug-target interactions via deep learning techniques[EB/OL]. 2020. <https://dspace.cuni.cz/handle/20.500.11956/116611>.
- [17]Morris G M, Goodsell D S, Halliday R S, et al. Automated docking using a Lamarckian genetic algorithm and an empirical binding free energy function[J/OL]. Journal of Computational Chemistry, 1998, 19(14):1639-1662. DOI: 10.1002/(SICI)1096-987X(19981115)19:14<1639::AID-JCC10>3.0.CO;2-B.

- [18]Öztürk H, Özgür A, Özkirimli E. DeepDTA: Deep Drug - Target Binding Affinity Prediction [J/OL]. *Bioinformatics*, 2018, 34(17):i821-i829. DOI: 10.1093/bioinformatics/bty593.
- [19]Nguyen T, Le H, Le T, et al. Prediction of drug - target binding affinity using graph neural networks[EB/OL]. 2019. <https://www.biorxiv.org/content/biorxiv/early/2020/10/02/684662.full.pdf>.
- [20]Chen R, Liu X, Jin S, et al. Machine Learning for Drug-Target Interaction Prediction[J/OL]. *Molecules*, 2018, 23(9):2208. DOI: 10.3390/molecules23092208.
- [21]Choi S R, Lee M. Transformer Architecture and Attention Mechanisms in Genome Data Analysis: A Comprehensive Review[J/OL]. *Biology*, 2023, 12(7):1033. DOI: 10.3390/biology12071033.
- [22]Shorten C, Khoshgoftaar T M. A survey on Image Data Augmentation for Deep Learning [J/OL]. *Journal of Big Data*, 2019, 6(1): 60. DOI: 10.1186/s40537-019-0197-0.
- [23]Cubuk E D, Zoph B, Mane D, et al. AutoAugment: Learning Augmentation Policies from Data[EB/OL]. 2019. <https://arxiv.org/abs/1805.09501>.
- [24]Yang S, Xiao W, Zhang M, et al. Image Data Augmentation for Deep Learning: A Survey [EB/OL]. 2022. <https://arxiv.org/abs/2204.08610>.
- [25]Bian J, Zhang X, Zhang X, et al. MCANet: shared-weight-based MultiheadCrossAttention network for drug-target interaction prediction[J/OL]. *Briefings in Bioinformatics*, 2023, 24(2): bbad082. DOI: 10.1093/bib/bbad082.
- [26]Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[EB/OL]. 2019. <https://arxiv.org/abs/1810.04805>.
- [27]Ahmad W, Simon E, Chithrananda S, et al. ChemBERTa-2: Towards Chemical Foundation Models[EB/OL]. 2022. <https://arxiv.org/abs/2209.01712>.
- [28]Tokuriki N, Tawfik D S. Protein dynamism and evolvability[J/OL]. *Science*, 2009, 324(5924): 203-207. DOI: 10.1126/science.1169375.
- [29]Han X, Zhang Z, Ding N, et al. Pre-trained models: Past, present and future[J/OL]. *AI Open*, 2021, 2:225-250. DOI: 10.1016/j.aiopen.2021.08.002.
- [30]Tang J, Szwajda A, Shakyawar S, et al. Making Sense of Large-Scale Kinase Inhibitor Bioactivity Data Sets: A Comparative and Integrative Analysis[J/OL]. *Journal of Chemical Information and Modeling*, 2014, 54(3): 735-743. DOI: 10.1021/ci400709d.

致 谢

四年的本科学习生活即将告一段落，回首这段时光，我满怀感激之情。首先，我要由衷感谢我的导师曾煜妮教授。在我本科学习的四年里，曾煜妮教授不仅是我的导师，更是我的良师益友。每一次学术研讨，每一次与导师的交流，都是我宝贵的成长经历。在面对学术难题时，曾教授总是耐心细致地为我解答，从不厌烦每一次问题的提出。同时，我也要感谢和我共参与各种竞赛的同学们。在这段时光里，我们同心协力，共同进步，展现了新一代青年的信仰与行动。他们的支持和鼓励让我在学业和生活上更加坚定和自信。特别感谢我的朋友们，在绝望与焦虑的

深夜里，他们的激励和倾听让我感受到了真挚的友情和支持。最后，我要感谢我的父母。是他们给了我生命，让我有机会去追求自己的梦想。他们的支持和鼓励是我不断向前的动力和底气。在此，我要衷心感谢每一位曾经帮助过我的人，你们的帮助和支持将永远铭记在我的心中。愿我们在未来的道路上继续努力奋斗，共同创造更加美好的明天。

LOW REN HONG 2025年5月8日

报告指标说明：

- 1.复写率：指相似或疑似重复内容在全文中的比重。
- 2.自引率：指引用本人发表内容占全文的比重，需正确标注引用。
- 3.他引率：指引用他人内容占全文的比重，需正确标注引用。
- 4.专业术语率：指公式定理、法律条文、行业用语等在全文中的比重。
- 5.去除本人引用相似率：指去除本人发表部分后，相似或引用内容占全文的比重，需正确标注引用。
- 6.去除专业术语相似率：指去除专业术语后，相似或引用内容占全文的比重。
- 7.自写率：指原创内容在全文中的比重。
- 8.典型相似文章：指相似或引用内容占全文总相似比超过30%的文章。

相似片段中“综合”包括：《中文主要报纸全文数据库》《中国专利特色数据库》《中国主要会议论文特色数据库》《港澳台文献资源》《图书资源》《维普优先出版论文全文数据库》《年鉴资源》《古籍文献资源》《IPUB原创作品》

须知：

- 报告编号系送检论文检测报告在本系统中的唯一编号
- 本报告为维普论文检测系统算法自动生成，仅对您所选择比对资源范围内检验结果负责，仅供参考。



微信公众号

唯一官网：<https://vpcs.fanyu.com> | 客服邮箱：vpcs@fanyu.com | 客服热线：400-607-5550 | 客服QQ：4006075550